

Projeto de portfólio Data processing

Neste projeto, serão utilizados conceitos de processamento e coleção de dados para auxiliar Porto real a conseguir introduzir 500 eletropostos em sua região.

Visto isso, será necessário criar um pipeline escalável em Data Lakehouse e usaremos a arquitetura Kappa por necessitar de apenas um único pipeline, menor latência, complexidade de manutenção menor, é adequada para cenários de IoT e coleção de dados em tempo real.

- **Estratégias de injeção**

Ademais, usaremos também Change data capture para lidar com mutabilidade, IoT com finalidade para streaming data lakes via dados em Json.

- **Organização do Data Lakehouse**

Também utilizaremos uma organização em estágios.

-Bronze para dados brutos;

-Prata para dados tratados;

-Ouro para dados analíticos;

- **Plano de tratamento de dados**

Será usado imputação ou descarte para dados nulos, validações de range para inconsistências e limpeza, tokenização e normalizações para análise de sentimento para textos.

- **Modelagem analítica**

Para a tabela fato, usaremos o consumo energético. Já as dimensões serão o tempo, cliente, estações e o sentimento de mercado.

- **Justificativa ETL vs ELT**

Utilizaremos ELT pois aproveita o poder de processamento do Lakehouse, permite ingestão rápida e transformação dentro do ambiente analítico e possui maior escalabilidade e manutenção mais simples.

- **Conclusão**

Todas estas escolhas foram selecionadas pelos seguintes motivos:

- A arquitetura proposta resolve o gargalo de latência;

- O pipeline entrega múltiplas fontes em tempo real;

- A modelagem analítica permite prever demanda e apoiar uma precificação dinâmica.